



Soutenance du Stage de deuxième année F4 Détermination d'un algorithme améliorant l'apprentissage d'un réseau de neurones

Julien Feuillas

ISIMA

23 Mai 2019

Objectifs du groupe MMIV

- MMIV (Mohn Medical Imaging and Visualization Centre)
 - Centre de recherche en termes d'imagerie médicale
 - Basé en Norvège
 - Dépendant de l'Université de Bergen
 - Représentante : Mme Renate Grüner
- Objectifs
 - Mettre en place de nouvelles techniques d'apprentissage automatique
 - Création d'offres personnalisées

Travaux réalisés dans le cadre du projet

- Stage de 6 mois
- Création de capteurs
 - Utilisation des téléphones portables des clients
 - Informations recueillies :
 - Puissance du signal
 - Adresse MAC
 - Date
- Mise en place d'une première solution
 - Acquisition de données
 - Algorithme de Machine Learning

Cadre du Projet

- Nos Objectifs
 - Calcul de la position des clients à un instant donné
 - Étude de différentes solutions
- Cadre d'étude
 - Calcul mathématique direct ?
 - Machine Learning
 - Classification
 - Régression

Problématique

Quelle est la méthode de Machine Learning la plus efficace pour effectuer de la localisation en environnement intérieur ?

Plan

- 1 Travaux précédents et Déroulement du Projet
- 2 Présentation des méthodes à implémenter
- 3 Résultats

Plan

- 1 Travaux précédents et Déroulement du Projet
- 2 Présentation des méthodes à implémenter
- 3 Résultats

Acquisition des données

- Découpage de la pharmacie en différentes zones
- Méthode d'acquisition des données :
 - Téléphone posé dans une zone
 - Émission de signaux pendant une certaine durée
- Stockage des données :
x;y;date;c1;c2;c3;c4

Découpage de la pharmacie

Machine Learning

- Vocabulaire :
 - Feature ($c1, c2, c3, c4$)
 - Target (x, y)
- Algorithmes paramétrés
- Deux étapes :
 - Entraînement
 - Test

Classification et Régression

- Classification

- Regroupement en classes
- Classes – Targets

- Régression

- Forme de la fonction : features \mapsto targets
- Minimisation de l'erreur
- Méthodes linéaires :

$$\begin{cases} t_1 = \alpha_{1,0} + \alpha_{1,1}f_1 + \dots + \alpha_{1,n}f_n \\ \vdots \\ t_m = \alpha_{m,0} + \alpha_{m,1}f_1 + \dots + \alpha_{m,n}f_n \end{cases}$$

Outils utilisés

- Python
- Bibliothèques Python :
 - Numpy
 - Scikit-Learn et Pandas
 - Matplotlib et Seaborn

Déroulement du projet

- Rendez-vous hebdomadaires
- Objectifs définis au cours du projet

Plan

- 1 Travaux précédents et Déroulement du Projet
- 2 **Présentation des méthodes à implémenter**
- 3 Résultats

Découpage du jeu de données

Méthodes de Classification

- K Nearest Neighbors
 - Recherche des voisins
 - Détermination de la classe
- Support Vector Machine (SVM)
 - Choix d'une méthode
 - Itération

Métriques pour la Classification

- Précision = $\frac{\text{Nombre de prédictions correctes}}{\text{Nombre de données}}$
- Matrice de confusion :

	A	B
A	2345	0
B	213	2143

Régressions linéaire et polynomiale

- Régression linéaire
 - Méthode des moindres carrés
 - Erreur : $\|\cdot\|_2^2$
- Régression polynomiale
 - Paramètre : degré
 - Exemple :
$$t = a_0 + a_1 f_1 + a_2 f_2 + a_3 f_1^2 + a_4 f_2^2 + a_5 f_1 f_2$$
 - Méthode linéaire ?

Régressions linéaires paramétrées

- Régression Ridge
 - Redondance d'information entre les individus
 - Coefficient de pénalité α
- Régression LASSO
 - Redondance d'information dans les features
 - Coefficient de pénalité α
- Régression Elastic-Net
 - Combinaison des méthodes précédentes
 - Deux Coefficients :
 - α : Coefficient de pénalité
 - $\rho \in [0, 1]$: Contrôle de la combinaison

Métriques pour la régression

- Erreur de "distance" :
 - Erreur quadratique :
 - $MSE(Y, Y_{pred}) = \frac{1}{N_{test}} \sum_{l=1}^{N_{test}} (Y_l - Y_{pred,l})^2$
 - Erreur moyenne absolue
 - $MAE(Y, Y_{pred}) = \frac{1}{N_{test}} \sum_{l=1}^{N_{test}} |Y_l - Y_{pred,l}|$
- Capacité de prédiction du modèle
 - Coefficient de détermination
 - $R^2(Y, Y_{pred}) = 1 - \frac{\sum_{l=1}^{N_{test}} (Y_l - Y_{pred,l})^2}{\sum_{l=1}^{N_{test}} (Y_l - \bar{Y})^2}$
 - Score de variance expliquée
 - $EVS(Y, Y_{pred}) = 1 - \frac{Var(Y - Y_{pred,l})}{Var(Y)}$

Efficacité des méthodes de régression

- Résultats dépendants du découpage initial
- Écriture d'une fonction Python :
 - `apply_regressions`
 - Plusieurs applications du même modèle de régression
 - Renvoie la valeur des métriques pour chaque application
 - Variables d'entrée :
 - Nombre de régressions
 - Le modèle à appliquer
 - Conservation des lignes dupliquées ?
- Utilisable pour la détermination de paramètres

Plan

- 1 Travaux précédents et Déroulement du Projet
- 2 Présentation des méthodes à implémenter
- 3 Résultats**

K Nearest Neighbors

- Précision = 98%

Support Vector Classification

- Précision = 68%

Détermination des paramètres : polynomiale

Détermination des paramètres : Ridge

Détermination des paramètres : LASSO

Détermination des paramètres : Elastic-Net

- Méthode précédente non utilisable
- Utilisation d'un objet déjà implémenté :
 - `MultiTaskElasticNetCV` de `sklearn.linear_model`
 - Validation croisée + méthode de régression
- Paramètre de construction :
 - Nombre de plis à effectuer
 - Un tableau de valeurs possibles pour α et ρ

Tableau de résultats

	Duplications ?	MSE	MAE	R2	EVS
Linéaire	oui	1.862	1.097	0.642	0.643
	non	2.061	1.158	0.602	0.606
Polynomiale	oui	0.900	0.666	0.824	0.825
	non	1.299	0.773	0.717	0.720
Elastic-Net	oui	1.864	1.098	0.642	0.642
	non	2.064	1.160	0.601	0.604

Comparaison entre classification et régression

- Efficacité de la régression :
 - Au sens des métriques de régression
 - Différentes des métriques de classification
- Passage régression \rightarrow classification
 - Pour la régression polynomiale

Passage de la régression à la classification

Résultats de la régression polynomiale pour la classification

- Résultats :
 - Précision : 54%
 - Termes extra-diagonaux de la matrice de confusion
- Résultats peu précis
 - Zones trop grandes
 - Nécessité d'un nouveau jeu de données

Graphique de densité

Résumé du travail réalisé

- Méthodes de régression implémentées
 - Méthodes linéaires
 - Méthodes probabilistes ? Régressions à noyau ?
- Résultats obtenus
 - Non concluants
 - Méthodes employées réutilisables
- Ce qu'il reste à faire
 - Mise en place de nouvelles régressions
 - Étude d'un nouveau jeu de données

Remerciements

Nous vous remercions pour votre attention